Taller – Análisis de Componentes Principales (ACP)

Base *Wine* (UCI Machine Learning Repository)

15 de octubre de 2026

Atribución del código. El análisis reutiliza y adapta el código del cuaderno de clase: Pacheco, M. (s.f.). *Análisis Multivariado* [Repositorio de código y material de clase]. `https://datastatistic.github.io/multivariate/` (archivo `code/python/02-mrd/Código_MRD_1_ACP.ipynb`).

Datos. Aeberhard, S. y Forina, M. (1992). *Wine* [Dataset]. UCI Machine Learning Repository. `https://doi.org/10.24432/C5PC7J`

Índice

Justificación de la base **2**

1. Carga y exploración inicial de los datos **2**

2. Análisis descriptivo univariado y matriz de correlaciones **3**

3. Preprocesamiento: faltantes y estandarización **6**

4. Verificación de supuestos y pertinencia del ACP **6**

5. Cálculo de las componentes principales "a mano" (DVS) **7**

6. Selección del número de componentes **7**

7. Visualización **9**

8. Interpretación sustantiva de las componentes **13**

9. Proyección de las observaciones, patrones y atípicos **15**

10. Conclusiones y limitaciones **18**

Referencias **18**

Justificación de la base

(i) Contexto. La base proviene del UCI Machine Learning Repository (donada en 1991; publicada por Forina et al., grupo PARVUS, Génova). Cada **fila es un vino** de la misma región de Italia, elaborado a partir de uno de **tres cultivares** (variedades de uva). Se midieron 13 constituyentes químicos por análisis de laboratorio. Hay $n = 178$ vinos, sin faltantes. Como la base no trae identificador, se crea `Vino_001`, ..., `Vino_178`.

Tabla 1: Diccionario de variables.

Variable (notebook)	Original UCI	Descripción
`alcohol`	Alcohol	Grado alcohólico (% vol.)
`ac_malico`	Malic acid	Ácido málico (acidez de origen frutal)
`ceniza`	Ash	Contenido de cenizas (minerales)
`alcal_ceniza`	Alcalinity of ash	Alcalinidad de las cenizas
`magnesio`	Magnesium	Magnesio
`fenoles_tot`	Total phenols	Fenoles totales
`flavonoides`	Flavanoids	Fenoles flavonoides
`fenoles_noflav`	Nonflavanoid phenols	Fenoles no flavonoides
`proantocianinas`	Proanthocyanins	Proantocianidinas (taninos condensados)
`int_color`	Color intensity	Intensidad de color
`tono`	Hue	Tonalidad del color
`od280_od315`	OD280/OD315	Razón de absorbancias (contenido proteico/fenólico)
`prolina`	Proline	Prolina (aminoácido)
`cultivar`	class	**Cualitativa**: cultivar 1, 2 o 3

(ii) Pregunta de investigación. ¿Es posible resumir las 13 mediciones químicas de los vinos en unos pocos ejes interpretables, y esos ejes permiten diferenciar los tres cultivares de uva?

(iii) Pertinencia del ACP. Varias variables miden aspectos del mismo fenómeno: fenoles totales, flavonoides, proantocianidinas y OD280/OD315 miden el contenido fenólico del vino, por lo que se espera que estén fuertemente correlacionadas (redundancia). Alcohol, color y prolina también se asocian con la madurez de la uva. Esa redundancia es la que el ACP puede resumir.

1. Carga y exploración inicial de los datos

La base tiene 178 vinos y 14 columnas: 13 variables cuantitativas continuas y una cualitativa (`cultivar`). No hay valores faltantes en ninguna variable (0 %).

Reflexión. Cada fila de la base representa el análisis de un vino específico y cada columna una característica química cuantitativa continua. Las variables cuantitativas se consideran *activas* porque intervienen directamente en el cálculo de las componentes principales y de la varianza total, mientras que el cultivar se considera *suplementaria*: no participa en la construcción de los ejes, pero se usa para interpretarlos.

2. Análisis descriptivo univariado y matriz de correlaciones

Tabla 2: Estadísticos descriptivos, coeficiente de variación (CV) y asimetría.

Variable	Media	Desv. est.	Mín.	Mediana	Máx.	CV (%)	Asimetría
alcohol	13.001	0.812	11.03	13.050	14.83	6.2	-0.05
ac_malico	2.336	1.117	0.74	1.865	5.80	47.8	1.03
ceniza	2.367	0.274	1.36	2.360	3.23	11.6	-0.18
alcal_ceniza	19.495	3.340	10.60	19.500	30.00	17.1	0.21
magnesio	99.742	14.282	70.00	98.000	162.00	14.3	1.09
fenoles_tot	2.295	0.626	0.98	2.355	3.88	27.3	0.09
flavonoides	2.029	0.999	0.34	2.135	5.08	49.2	0.03
fenoles_noflav	0.362	0.124	0.13	0.340	0.66	34.4	0.45
proantocianinas	1.591	0.572	0.41	1.555	3.58	36.0	0.51
int_color	5.058	2.318	1.28	4.690	13.00	45.8	0.86
tono	0.957	0.229	0.48	0.965	1.71	23.9	0.02
od280_od315	2.612	0.710	1.27	2.780	4.00	27.2	-0.30
prolina	746.893	314.907	278.00	673.500	1680.00	42.2	0.76

Las escalas son muy distintas: `prolina` tiene media $\approx$ 747 y desviación $\approx$ 315, `magnesio` $\approx$ 100, mientras que `fenoles_noflav` o `tono` están por debajo de 1. Los mayores coeficientes de variación los tienen `flavonoides` ($\approx$ 49 %), `ac_malico` ($\approx$ 48 %) e `int_color` ($\approx$ 46 %); los menores, `alcohol` ($\approx$ 6 %) y `ceniza` ($\approx$ 12 %).

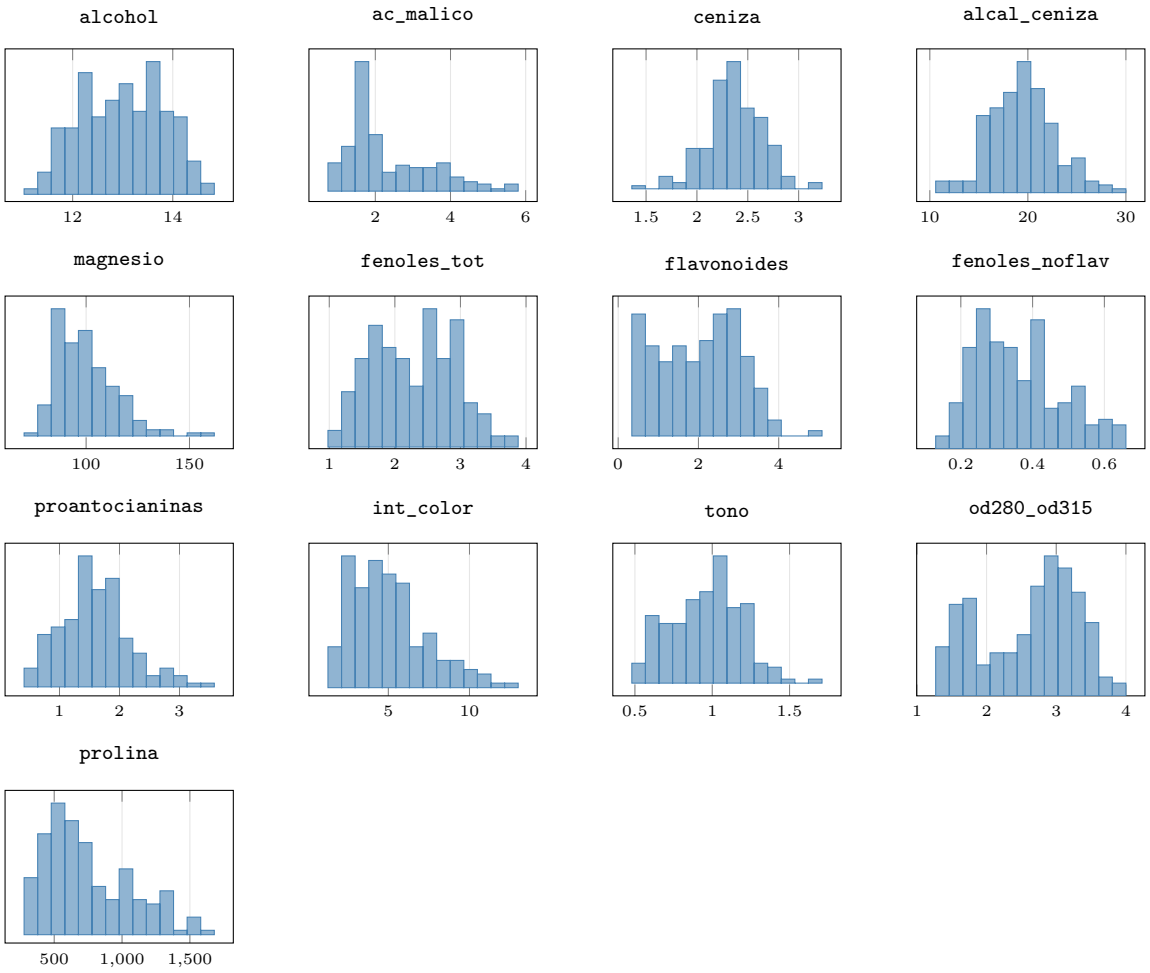


Figura 1: Histogramas de las 13 variables químicas.

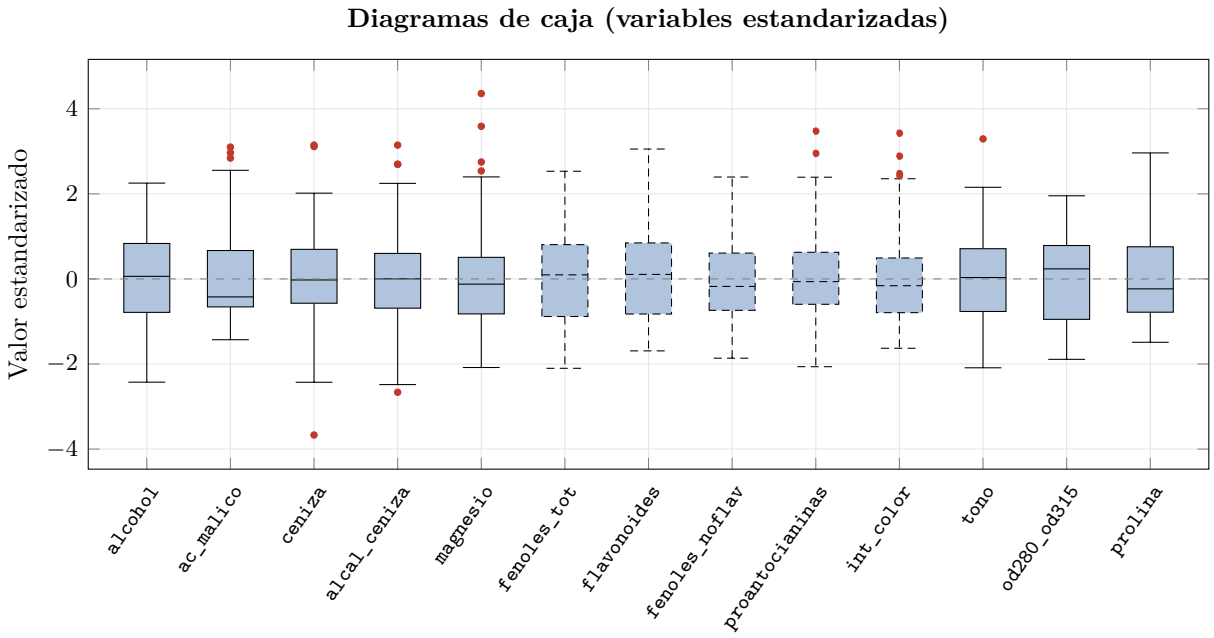


Figura 2: Diagramas de caja de las variables estandarizadas; los puntos rojos son atípicos según la regla de $1.5 \cdot \text{RIC}$.

`ac_malico` (asimetría ≈ 1.0), `magnesio` (≈ 1.1), `int_color` (≈ 0.9) y `prolina` (≈ 0.8) tienen asimetría positiva (cola a la derecha); el resto es aproximadamente simétrico ($|\text{asimetría}| < 0.5$). Por la regla de 1.5·RIC hay pocos atípicos univariados: 4 en `alcal_ceniza`, `magnesio` e `int_color`; 3 en `ac_malico` y `ceniza`; 2 en `proantocianinas` y 1 en `tono`. Los valores extremos son químicamente plausibles (no parecen errores de digitación), por lo que se conservan.

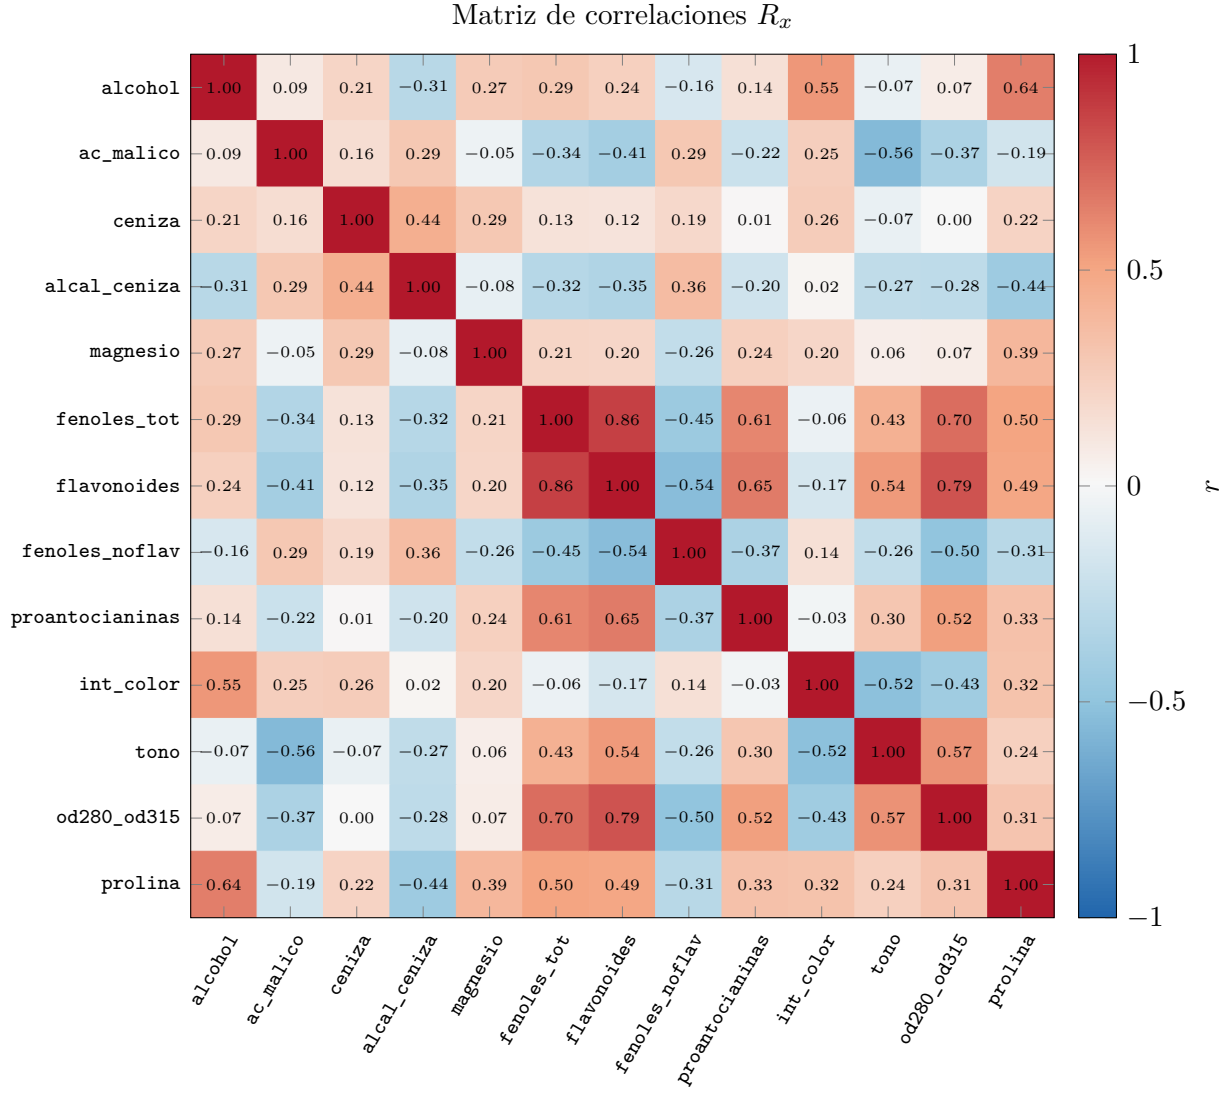


Figura 3: Mapa de calor de la matriz de correlaciones R_x.

Interpretación por bloques.

- **Bloque fenólico:** `fenoles_tot`, `flavonoides`, `proantocianinas` y `od280_od315` tienen correlaciones positivas altas entre sí (≈ 0.6–0.86; flavonoides–fenoles totales ≈ 0.86). `tono` también se une a este bloque; `fenoles_noflav` y `ac_malico` se correlacionan negativamente con él.
- **Bloque alcohol/color/prolina:** `alcohol`, `int_color` y `prolina` se correlacionan positivamente (alcohol–prolina ≈ 0.64; alcohol–color ≈ 0.55).
- **Bloque mineral:** `ceniza` y `alcal_ceniza` se correlacionan moderadamente (≈ 0.44) y casi no se relacionan con el resto.

Reflexión. Al observar R_x se identifican aproximadamente 3 o 4 factores principales que agrupan y explican la variabilidad de los atributos químicos del vino.

3. Preprocesamiento: faltantes y estandarización

Con `dropna()` se pierden **0 observaciones** (la base no tiene faltantes) y se conservan $178 \geq 100$. Se construye la matriz estandarizada y ponderada

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j\sqrt{n-1}}, \qquad i = 1, \ldots, 178,\ j = 1, \ldots, 13,$$

que cumple $Z^\top Z = R_x$ (diferencia máxima $\approx 1.6 \times 10^{-15}$, es decir, error de redondeo).

Tabla 3: Varianza de cada variable sin estandarizar y su peso en la traza de la matriz de covarianzas.

Variable	Varianza	% de la varianza total
`prolina`	99 166.717	99.774
`magnesio`	203.989	0.205
`alcal_ceniza`	11.153	0.011
`int_color`	5.374	0.005
Resto (9 variables)	< 1.3	< 0.005

Reflexión. Es necesario estandarizar porque las variables están en unidades y órdenes de magnitud muy dispares. Sin estandarizar, la matriz de covarianzas estaría dominada por `prolina` (99.8 % de la varianza total) y `magnesio`; el ACP reflejaría casi únicamente la variabilidad de esas variables y no permitiría interpretar las demás.

4. Verificación de supuestos y pertinencia del ACP

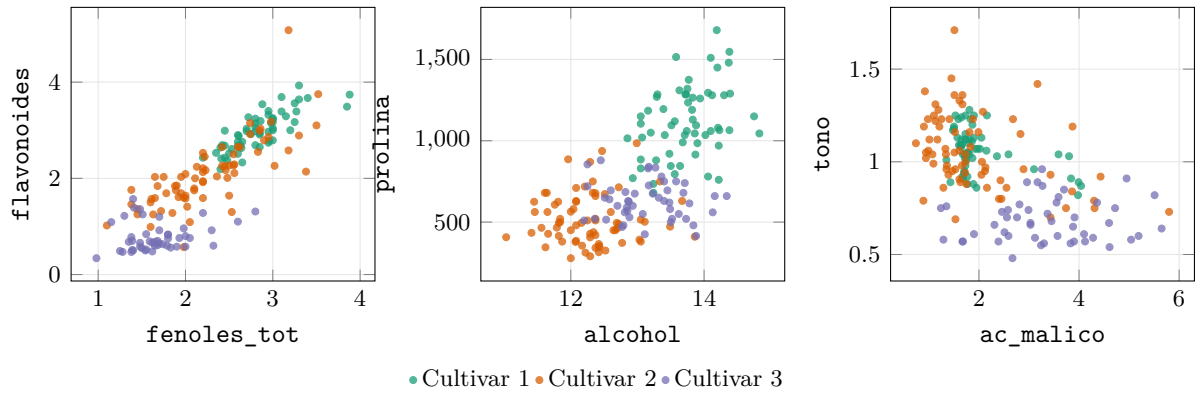


Figura 4: Diagramas de dispersión de pares representativos (bloque fenólico y variables asimétricas).

Las relaciones dentro del bloque fenólico son claramente lineales y no se observan relaciones curvas marcadas. Las variables asimétricas (`prolina`, `int_color`, `ac_malico`, `magnesio`) muestran nubes en abanico (más dispersión en valores altos). La Tabla 4 lo comprueba: al aplicar logaritmo la correlación de Pearson casi no cambia y coincide con la de Spearman, es decir, las relaciones son monótonas y prácticamente lineales. Se trabaja en la escala original.

Tabla 4: ¿Mejora la linealidad con logaritmo? Pearson vs. Spearman.

Par	Pearson original	Pearson (log)	Spearman
`prolina`–`alcohol`	0.644	0.637	0.634
`ac_malico`–`tono`	−0.561	−0.562	−0.560

Determinante de R_x. $\det(R_x) = 0.000469 \approx 0.00047$, muy cercano a 0 (el máximo posible, con variables incorrelacionadas, sería 1). La varianza generalizada es muy pequeña: la nube de puntos en 13 dimensiones está "aplastada" en algunas direcciones porque hay mucha redundancia lineal entre las variables. Esto justifica el ACP.

5. Cálculo de las componentes principales "a mano" (DVS)

Se aplica la descomposición en valores singulares

$$Z = P\,\Delta\,Q^\top, \qquad \lambda_k = \delta_k^2, \qquad F = Z\,Q = P\,\Delta,$$

donde Q contiene los vectores propios de $Z^\top Z = R_x$ y P los de $ZZ^\top$. Se verificaron numéricamente todas las propiedades:

- $F = P\Delta$ y $Q^\top Q = I_{13}$.
- $\sum_k \lambda_k = 13 = p$.
- $\mathrm{Var}(F_k) = \lambda_k/(n-1)$, es decir, proporcional a λ_k con constante $1/177$.
- Las componentes son incorrelacionadas: $\max_{k\neq l} |\,\mathrm{cor}(F_k, F_l)| \approx 1.4 \times 10^{-15}$.

Los valores propios de la DVS coinciden con los de `eigh(cor(X))`. Los vectores coinciden en valor absoluto, pero algunas columnas salen con **signo cambiado**: si q_k es vector propio de R_x, también lo es $-q_k$, pues $R_x(-q_k) = \lambda_k(-q_k)$ y $\|-q_k\| = 1$. Cada algoritmo elige el signo de forma arbitraria; invertirlo solo refleja el eje y no cambia la varianza ni la interpretación, siempre que se lean juntos cargas y coordenadas.

6. Selección del número de componentes

Tabla 5: Valores propios e inercia.

Componente	λ_k	Inercia (%)	Inercia acumulada (%)
CP1	4.706	36.199	36.199
CP2	2.497	19.207	55.406
CP3	1.446	11.124	66.530
CP4	0.919	7.069	73.599
CP5	0.853	6.563	80.162
CP6	0.642	4.936	85.098
CP7	0.551	4.239	89.337
CP8	0.348	2.681	92.018
CP9	0.289	2.222	94.240
CP10	0.251	1.930	96.170
CP11	0.226	1.737	97.907
CP12	0.169	1.298	99.205
CP13	0.103	0.795	100.000

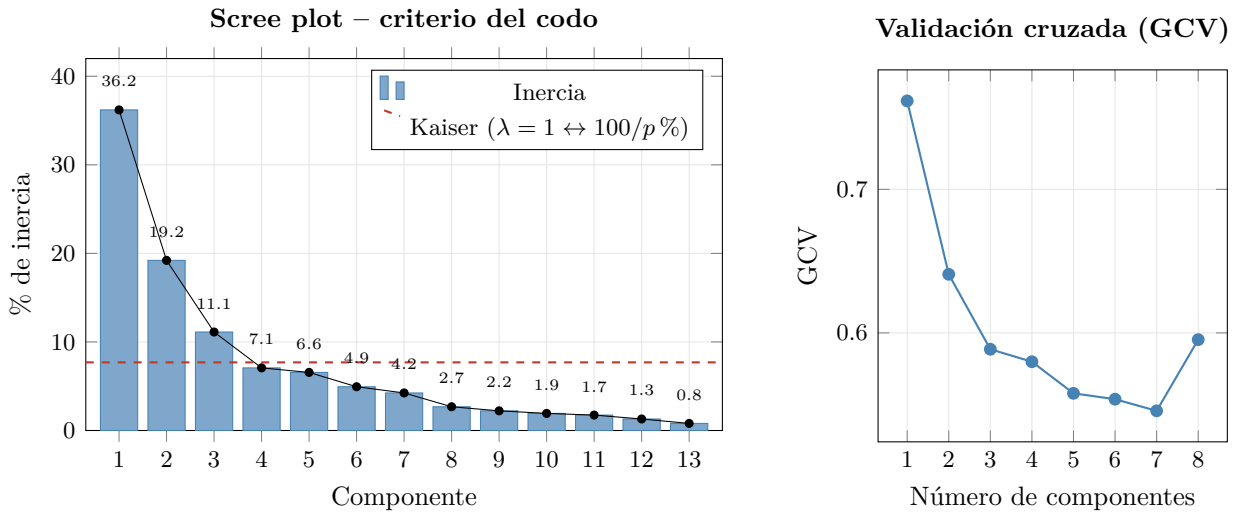


Figura 5: Izquierda: porcentaje de inercia por componente con la línea de Kaiser. Derecha: criterio GCV.

Tabla 6: Comparación de criterios.

Criterio	k sugerido	Inercia acumulada con ese k (%)
Kaiser ($\lambda > 1$)	3	66.5
Inercia acumulada $\geq 70\,\%$	4	73.6
Codo (scree plot)	3	66.5
GCV (validación cruzada)	7	89.3

Decisión. Kaiser y el codo sugieren $k = 3$, que explica $\approx 66.5\,\%$ de la inercia, apenas por debajo del $70\,\%$. Llegar al $70\,\%$ exige una cuarta componente con $\lambda_4 \approx 0.92 < 1$: aporta menos que una sola variable original y su inercia ($\approx 7.1\,\%$) es casi igual a la de CP5 ($\approx 6.6\,\%$), por lo que no forma un eje estable. El GCV sugiere 7, pero su curva es casi plana desde $k = 3$ ($0.589 \to 0.546$) y CP4–CP7 tienen $\lambda < 1$. Se retienen $k = 3$ **componentes** (CP1 $\approx 36.2\,\%$, CP2 $\approx 19.2\,\%$, CP3 $\approx 11.1\,\%$).

Reflexión. Cuando los criterios no coinciden se debe priorizar el porcentaje de varianza acumulada junto con la interpretabilidad. Si un número de componentes retiene un porcentaje satisfactorio de la inercia y permite una interpretación química clara respecto a la pregunta de investigación, es preferible, aunque un criterio estricto sugiera añadir una dimensión más.

7. Visualización

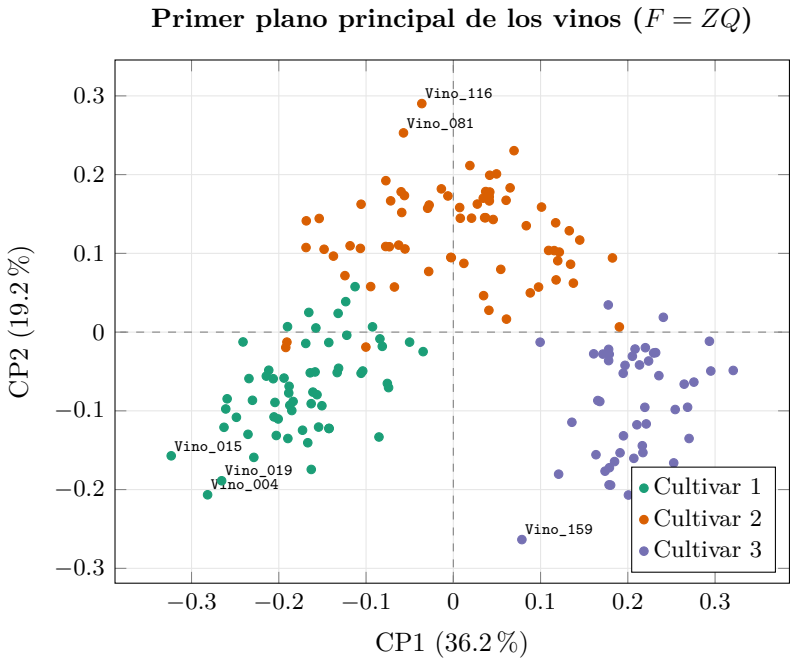


Figura 6: Proyección de los vinos en el primer plano principal; se etiquetan los 8 vinos con mayor contribución.

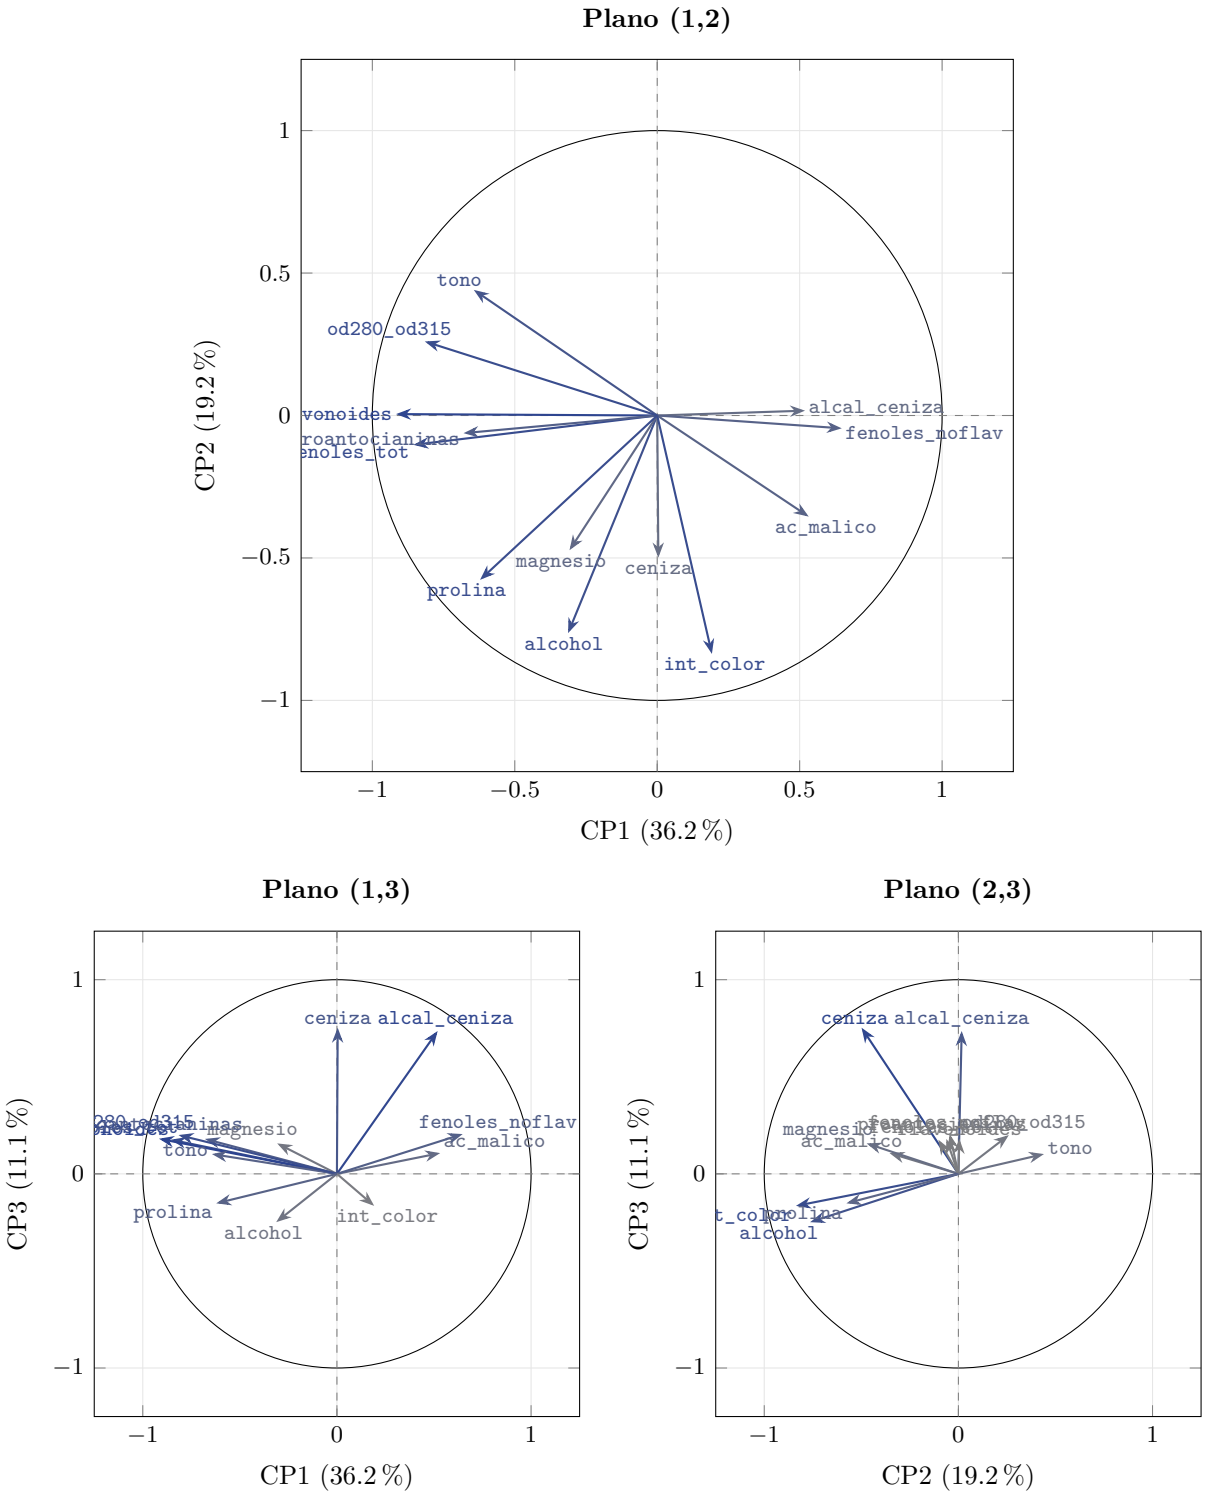

<antocianinas>
<enoles_tot>
<od280_od315>
<tono>
<alcal_ceniza>
<fenoles_noflav>
<ac_malico>
<magnesio>
<ceniza>
<prolina>
<alcohol>
<int_color>
Plano (1,2)
CP1 (36.2 %)
CP2 (19.2 %)
Plano (1,3)
CP1 (36.2 %)
CP3 (11.1 %)
Plano (2,3)
CP2 (19.2 %)
CP3 (11.1 %)

Figura 7: Círculos de correlaciones construidos con $R_{cv} = \text{cor}(Z, F)$. La intensidad del color de cada flecha es proporcional a su $\cos^2$ en el plano (más oscuro = mejor representada).

<antocianinas>
<enoles_tot>
<od280_od315>
<tono>
<alcal_ceniza>
<fenoles_noflav>
<ac_malico>
<magnesio>
<ceniza>
<prolina>
<alcohol>
<int_color>
Plano (1,2)
CP1 (36.2 %)
CP2 (19.2 %)
Plano (1,3)
CP1 (36.2 %)
CP3 (11.1 %)
Plano (2,3)
CP2 (19.2 %)
CP3 (11.1 %)

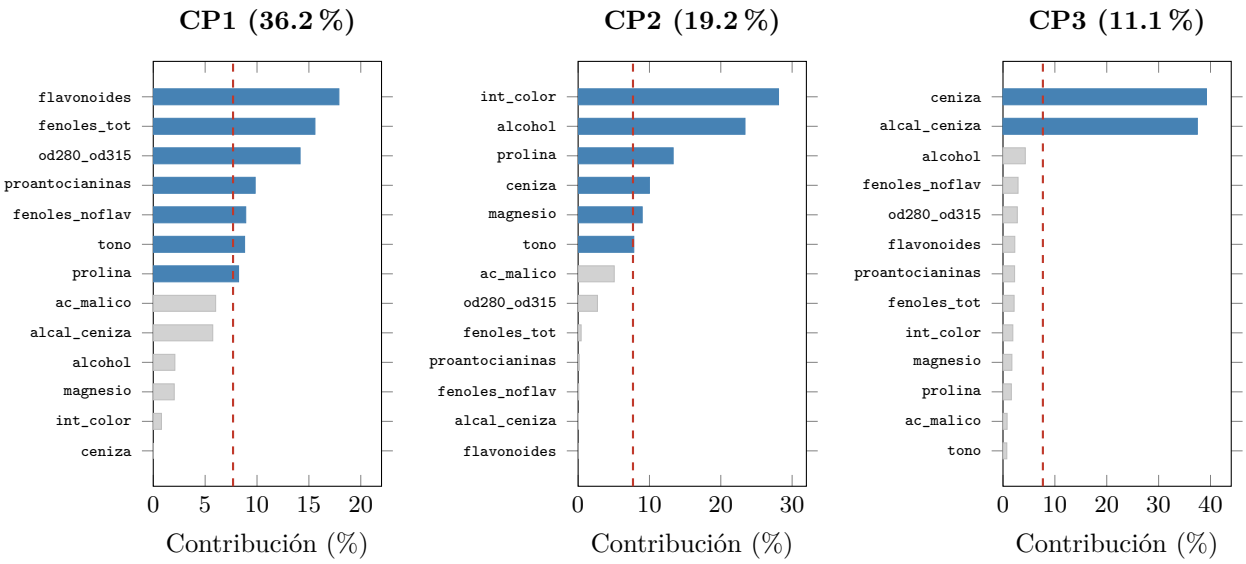


Figura 8: Contribución de las variables a cada componente retenida. La línea roja marca la contribución de referencia $1/p = 7.69\,\%$; en azul las variables que la superan.

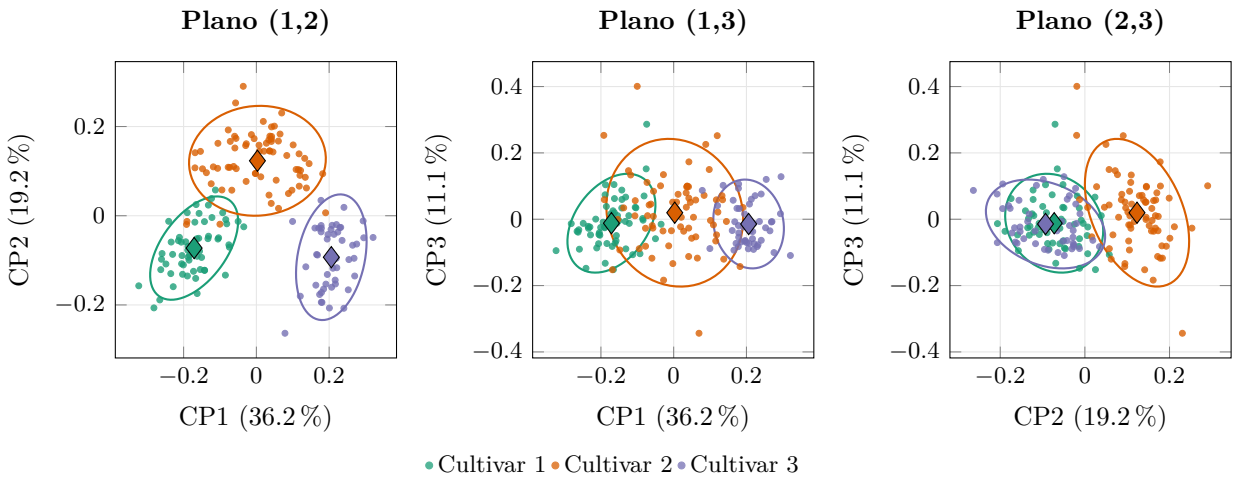


Figura 9: Vinos por cultivar en los planos (1,2), (1,3) y (2,3), con elipses de 2 desviaciones estándar y centroides (⧫).

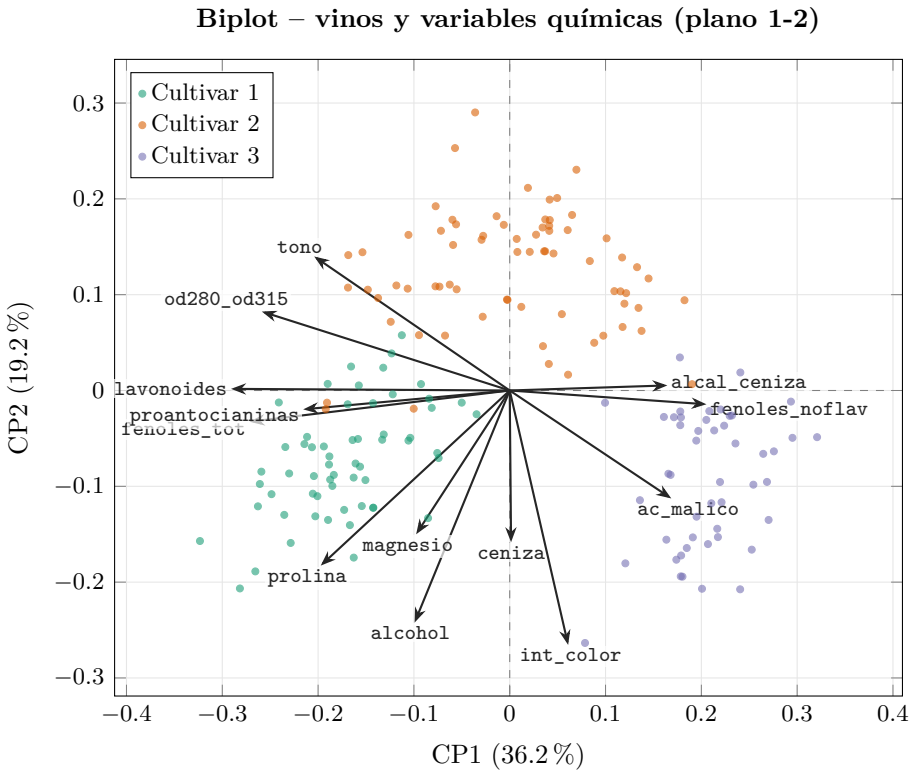


Figura 10: Biplot del primer plano: individuos y variables (flechas reescaladas a la escala de las coordenadas).

Lectura de los gráficos. En el primer plano ($\approx 55.4\,\%$ de la inercia) los tres cultivares forman tres nubes casi separadas en forma de arco. CP1 separa el cultivar 1 (izquierda) del cultivar 3 (derecha), y CP2 aísla al cultivar 2 (arriba). En los planos (1,3) y (2,3) la CP3 no separa los cultivares: las elipses se superponen verticalmente.

Reflexión. El biplot muestra simultáneamente observaciones y variables, lo que facilita ver qué características químicas explican la posición de cada grupo de vinos, algo que por separado el gráfico de individuos y el círculo de correlaciones no muestran. Su limitación es que, al visualizar solo dos dimensiones, se pierde la información de las componentes de orden superior.

8. Interpretación sustantiva de las componentes

Tabla 7: Cargas (Q), correlaciones (R_{cv}), $\cos^2$ y contribuciones de las variables a cada componente retenida.

Variable	Carga (Q)	R_{cv}	$\cos^2$	ctr (%)	ctr $> 1/p$	$\cos^2 > 0.3$
CP1 (36.2 %)						
flavonoides	-0.423	-0.917	0.842	17.887	✓	✓
fenoles_tot	-0.395	-0.856	0.733	15.576	✓	✓
od280_od315	-0.376	-0.816	0.666	14.150	✓	✓
proantocianinas	-0.313	-0.680	0.462	9.824	✓	✓
fenoles_noflav	0.299	0.648	0.419	8.912	✓	✓
tono	-0.297	-0.644	0.414	8.804	✓	✓
prolina	-0.287	-0.622	0.387	8.223	✓	✓
ac_malico	0.245	0.532	0.283	6.012		
alcal_ceniza	0.239	0.519	0.270	5.727		
alcohol	-0.144	-0.313	0.098	2.083		
magnesio	-0.142	-0.308	0.095	2.016		
int_color	0.089	0.192	0.037	0.785		
ceniza	0.002	0.004	0.000	0.000		
CP2 (19.2 %)						
int_color	-0.530	-0.837	0.701	28.090	✓	✓
alcohol	-0.484	-0.764	0.584	23.392	✓	✓
prolina	-0.365	-0.577	0.332	13.315	✓	✓
ceniza	-0.316	-0.499	0.249	9.990	✓	
magnesio	-0.300	-0.473	0.224	8.978	✓	
tono	0.279	0.441	0.195	7.797	✓	
ac_malico	-0.225	-0.355	0.126	5.059		
od280_od315	0.164	0.260	0.068	2.706		
fenoles_tot	-0.065	-0.103	0.011	0.423		
proantocianinas	-0.039	-0.062	0.004	0.154		
fenoles_noflav	-0.029	-0.045	0.002	0.083		
alcal_ceniza	0.011	0.017	0.000	0.011		
flavonoides	0.003	0.005	0.000	0.001		
CP3 (11.1 %)						
ceniza	0.626	0.753	0.567	39.216	✓	✓
alcal_ceniza	0.612	0.736	0.542	37.464	✓	✓
alcohol	-0.207	-0.249	0.062	4.301		
fenoles_noflav	0.170	0.205	0.042	2.903		
od280_od315	0.166	0.200	0.040	2.756		
flavonoides	0.151	0.181	0.033	2.271		
proantocianinas	0.149	0.180	0.032	2.234		
fenoles_tot	0.146	0.176	0.031	2.137		
int_color	-0.137	-0.165	0.027	1.885		
magnesio	0.131	0.157	0.025	1.710		
prolina	-0.127	-0.152	0.023	1.606		
ac_malico	0.089	0.107	0.011	0.792		
tono	0.085	0.102	0.011	0.726		

Tabla 8: Lectura técnica de cada eje (magnitudes grandes de R_{cv} agrupadas por signo; el signo es arbitrario).

Eje	Lado negativo	Lado positivo	Cultivar en cada lado
CP1	`flavonoides` (−0.92), `fenoles_tot` (−0.86), `od280_od315` (−0.82), `proantocianinas` (−0.68), `tono` (−0.64), `prolina` (−0.62)	`fenoles_noflav` (0.65), `ac_malico` (0.53), `alcal_ceniza` (0.52)	Negativo: cultivar 1. Positivo: cultivar 3
CP2	`int_color` (−0.84), `alcohol` (−0.76), `prolina` (−0.58), `ceniza` (−0.50), `magnesio` (−0.47)	`tono` (0.44)	Negativo: cultivares 1 y 3. Positivo: cultivar 2
CP3	–	`ceniza` (0.75), `alcal_ceniza` (0.74)	No separa cultivares

CP1 (36.2 %): eje de riqueza fenólica y calidad antioxidante. Es la dimensión más importante: concentra más de un tercio de la variabilidad total. Mide la intensidad del perfil antioxidante y la complejidad química derivada de los compuestos fenólicos. Con el signo que entrega la DVS, los valores *negativos* corresponden a vinos con alta concentración de flavonoides, fenoles totales y proantocianidinas (cultivar 1), típicamente asociados a vinos de mayor cuerpo y estructura; los positivos, a vinos con más fenoles no flavonoides y ácido málico (cultivar 3).

CP2 (19.2 %): eje de perfil cromático, alcohol y madurez. Capta casi una quinta parte de la información. Lo dominan la intensidad de color, el alcohol y la prolina, opuestos al tono. Un vino en los extremos de este eje se diferencia principalmente por la intensidad u oscuridad de su color y su grado alcohólico, independientemente de su cantidad de fenoles totales. Los vinos del cultivar 2 (más claros y menos alcohólicos) quedan en el lado positivo.

CP3 (11.1 %): eje de composición mineral. Aporta una décima parte de la variabilidad y recoge casi exclusivamente `ceniza` y `alcal_ceniza`, variables inorgánicas que no fueron explicadas por los dos primeros ejes. Describe el fondo mineral del vino y no discrimina entre cultivares.

9. Proyección de las observaciones, patrones y atípicos

Tabla 9: Vinos mejor representados ($\cos^2$) y que más contribuyen (ctr) a cada componente. Contribución promedio de un vino: $100/n = 0.562\,\%$.

	Mejor representados			Mayor contribución		
CP	Vino	$\cos^2$	Cult.	Vino	ctr (%)	Cult.
CP1	Vino_171	0.820	3	Vino_015	2.221	1
	Vino_137	0.780	3	Vino_147	2.188	3
	Vino_166	0.772	3	Vino_138	1.850	3
	Vino_148	0.765	3	Vino_137	1.831	3
	Vino_036	0.751	1	Vino_004	1.685	1
CP2	Vino_081	0.830	2	Vino_116	3.373	2
	Vino_117	0.805	2	Vino_159	2.780	3
	Vino_104	0.737	2	Vino_081	2.563	2
	Vino_107	0.699	2	Vino_060	2.125	2
	Vino_098	0.670	2	Vino_117	1.791	2
CP3	Vino_026	0.769	1	Vino_122	11.101	2
	Vino_122	0.751	2	Vino_060	8.167	2
	Vino_128	0.660	2	Vino_026	5.672	1
	Vino_123	0.633	2	Vino_074	4.424	2
	Vino_060	0.613	2	Vino_128	4.389	2

Tabla 10: Coordenadas de tres vinos concretos y su calidad de representación en el espacio de 3 componentes.

Vino	Cultivar	CP1	CP2	CP3	$\cos^2$ (3 CP)
Vino_159	3	0.079	-0.263	0.087	0.498
Vino_074	2	-0.192	-0.020	0.253	0.622
Vino_122	2	-0.100	-0.019	0.401	0.800

Variable	Vino_159	Vino_074	Vino_122	Media C1	Media C2	Media C3
`alcohol`	14.34	12.99	11.56	13.74	12.28	13.15
`ac_malico`	1.68	1.67	2.05	2.01	1.93	3.33
`ceniza`	2.70	2.60	3.23	2.46	2.24	2.44
`alcal_ceniza`	25.00	30.00	28.50	17.04	20.24	21.42
`magnesio`	98.00	139.00	119.00	106.34	94.55	99.31
`fenoles_tot`	2.80	3.30	3.18	2.84	2.26	1.68
`flavonoides`	1.31	2.89	5.08	2.98	2.08	0.78
`fenoles_noflav`	0.53	0.21	0.47	0.29	0.36	0.45
`proantocianinas`	2.70	1.96	1.87	1.90	1.63	1.15
`int_color`	13.00	3.35	6.00	5.53	3.09	7.40
`tono`	0.57	1.31	0.93	1.06	1.06	0.68
`od280_od315`	1.96	3.50	3.69	3.16	2.79	1.68
`prolina`	660.00	985.00	465.00	1115.71	519.51	629.90

Perfil químico de los tres vinos frente al promedio de cada cultivar.

- **Vino_122** (cultivar 2): es el que más contribuye a CP3 ($\approx 11.1\,\%$ frente al promedio de $0.56\,\%$) y está muy bien representado en ese eje ($\cos^2 \approx 0.75$). Tiene el máximo de la base en `ceniza` (3.23) y en `flavonoides` (5.08), y una alcalinidad de cenizas muy alta (28.5 frente a 20.2 de su cultivar). Por eso queda arriba del todo en el plano (1,3). También es el mayor atípico en ambas

estadísticas d^2.

- **Vino_159** (cultivar 3): segundo mayor contribuyente a CP2 ($\approx 2.8\,\%$), con coordenada muy negativa en ese eje. Tiene la máxima intensidad de color de la base (13.0) y más alcohol (14.3) que el promedio de su cultivar (13.2): es una versión "extrema" del perfil alcohol–color.
- **Vino_074** (cultivar 2): tiene la alcalinidad de cenizas máxima (30.0) y magnesio alto (139 frente a 94.6 de su cultivar). Contribuye $\approx 4.4\,\%$ a CP3 y está entre los atípicos por d^2_{1i}. Aunque es del cultivar 2, en el plano (1,2) queda lejos del centro de su grupo.

Indicador I_1 en $[0, 1]$

I_1 reescala la CP1 al intervalo $[0, 1]$ usando cuartiles y $3 \cdot \text{RIC}$, de modo que un vino extremo no fija por sí solo los límites; por eso los valores observados quedan entre ≈ 0.36 y 0.65. El signo de la CP1 en `sklearn` es **opuesto** al de la DVS a mano, así que en I_1 los valores altos corresponden al lado fenólico. Los 5 máximos son todos del cultivar 1 (Vino_015, 004, 019, 053, 011) y los 5 mínimos del cultivar 3 (Vino_147, 138, 137, 172, 156).

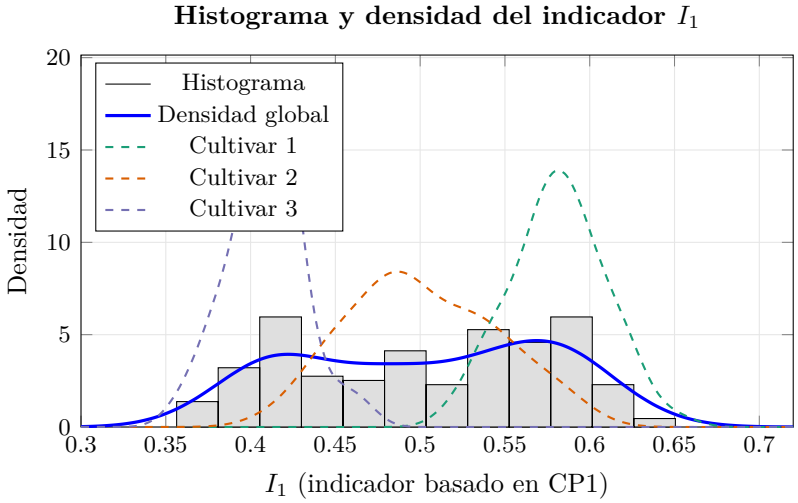


Figura 11: Distribución de I_1: la densidad global es ancha porque mezcla tres modos, uno por cultivar.

La densidad global es ancha y casi plana porque mezcla tres grupos: cada cultivar forma su propio modo (cultivar 3 ≈ 0.41, cultivar 2 ≈ 0.49, cultivar 1 ≈ 0.58), y el cultivar 2 se traslapa con los otros dos.

Atípicos multivariados: d^2_{1i} y d^2_{2i}

$$d^2_{1i} = \sum_{k=1}^{p_1} \frac{f^2_{ik}}{\lambda_k}, \qquad d^2_{2i} = \sum_{k=p-q+1}^{p} \frac{f^2_{ik}}{\lambda_k},$$

con $p_1 = 3$ (componentes retenidas) y $q = 2$ (últimas componentes, $\lambda_{12}, \lambda_{13} < 0.2$). El umbral es el cuantil empírico del 95 %.

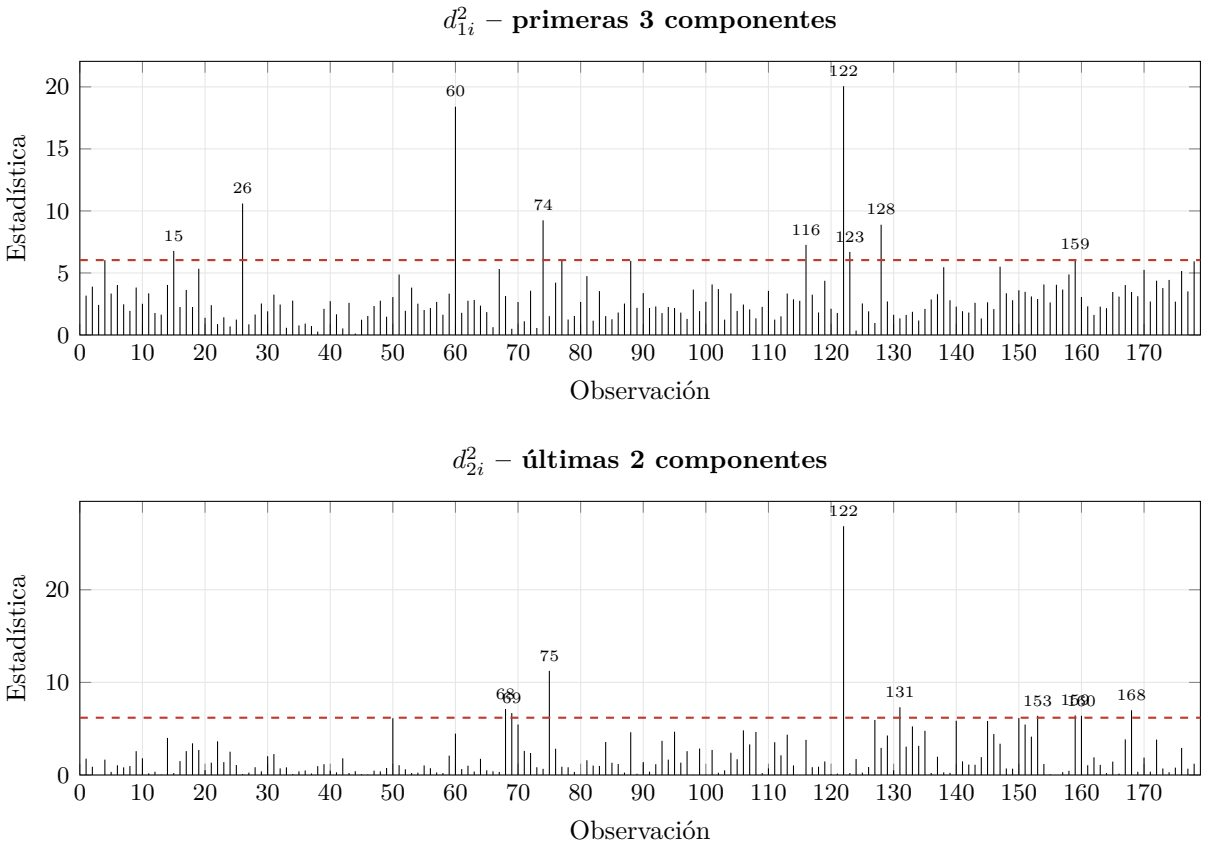


Figura 12: Estadísticas de atípicos por observación; la línea roja es el cuantil 95 % (d^2_1: 6.037; d^2_2: 6.185). Se etiqueta el número de cada vino atípico.

Tabla 11: Vinos atípicos según cada estadística.

Estadística	Vinos atípicos (cultivar)
d^2_{1i} ($p_1 = 3$)	015 (1), 026 (1), 060 (2), 074 (2), 116 (2), **122** (2), 123 (2), 128 (2), **159** (3)
d^2_{2i} ($q = 2$)	068 (2), 069 (2), 075 (2), **122** (2), 131 (3), 153 (3), **159** (3), 160 (3), 168 (3)

Con $\alpha = 0.05$ cada estadística marca 9 vinos ($\approx 5\,\%$ de 178). Solo **Vino_122** y **Vino_159** aparecen en ambas. Los atípicos de d^2_{1i} son casi todos del cultivar 2 y coinciden con los mayores contribuyentes a CP2/CP3; los de d^2_{2i} son en su mayoría distintos.

- d^2_{1i} mide qué tan lejos está un vino del centro **dentro del subespacio retenido**. Detecta versiones "exageradas" del patrón general (mucho color/alcohol o mucha ceniza), que pueden inflar la varianza de las primeras componentes.
- d^2_{2i} mide la distancia en las direcciones donde casi no hay variabilidad. Detecta vinos que **rompen la estructura de correlación**: combinaciones inusuales (p. ej., muchos fenoles totales pero pocos flavonoides) aunque cada valor por separado sea normal. Son invisibles en el primer plano.

Reflexión. Los valores atípicos pueden distorsionar los resultados del ACP, porque la varianza y la covarianza son sensibles a valores extremos: unos pocos vinos pueden dominar la dirección de los ejes y llevar a una interpretación incorrecta.

10. Conclusiones y limitaciones

a) Respuesta a la pregunta de investigación. Las 13 mediciones químicas se redujeron a tres componentes principales que retienen el 66.5 % de la inercia total (CP1: 36.2 %, CP2: 19.2 %, CP3: 11.1 %). Estas dimensiones tienen un sentido químico claro y coherente con la conjetura inicial: CP1 representa la riqueza fenólica y calidad antioxidante; CP2, el perfil cromático y de madurez (color, alcohol, prolina); CP3, la composición mineral. Al proyectar las observaciones en el primer plano factorial, los tres cultivares se separan de manera clara. Las diferencias químicas entre variedades no están dispersas al azar, sino concentradas en estas dimensiones latentes (lideradas por la riqueza fenólica y el color), lo que valida el ACP como herramienta de reducción de dimensionalidad para este conjunto de datos.

b) Información perdida. Con $k = 3$ se retiene $\approx 66.5\,\%$ de la inercia y se pierde $\approx \mathbf{33.5}\,\%$. La pérdida es aceptable para el objetivo: las 10 componentes descartadas tienen $\lambda < 1$ y la separación de los cultivares ya se logra en el primer plano. Si el objetivo fuera reconstruir con precisión cada medición, convendría retener 5 componentes ($\approx 80\,\%$).

c) Limitaciones.

1. **Linealidad.** El ACP solo captura relaciones lineales; las variables asimétricas generan nubes en abanico que la correlación de Pearson resume solo parcialmente.
2. **Sensibilidad a atípicos y a la escala.** Unos pocos vinos extremos (p. ej., Vino_122, que aporta 11 % de la inercia de CP3) influyen en las correlaciones y en la dirección de los ejes. Además, el resultado depende de haber estandarizado.
3. **Signo arbitrario de los ejes.** El sentido de cada componente lo decide el algoritmo (DVS, `eigh`, `sklearn`); hay que verificarlo antes de afirmar "más alto = más fenólico".
4. **Ejes con poca inercia.** La CP3 depende casi solo de dos variables, por lo que su interpretación es menos robusta; la CP4 quedó por fuera aunque está cerca del umbral.
5. **Representatividad.** Son 178 vinos de una sola región italiana y tres cultivares, analizados hace más de 30 años; las conclusiones no se generalizan a otras regiones, añadas o variedades.

d) Trabajo futuro.

- Comparar con un **ACP robusto** (MCD o *projection pursuit*) para medir cuánto cambian los ejes sin los atípicos.
- Usar **análisis discriminante lineal** con el cultivar como respuesta, para evaluar si las 3 componentes bastan para predecir la variedad.
- Ampliar con datos de **Wine Quality** (UCI) o variables sensoriales, para relacionar los ejes químicos con la calidad percibida.

Referencias

Aeberhard, S. y Forina, M. (1992). *Wine* [Dataset]. UCI Machine Learning Repository. `https://doi.org/10.24432/C5PC7J`

Pacheco, M. (s.f.). *Análisis Multivariado* [Repositorio de código y material de clase]. `https://datastatistic.github.io/multivariate/`